강의 1: Variational Autoencoder (VAE) — 상세 수식 풀이 포함

---

1. 생성 모델의 목표

1.1 핵심 아이디어

생성 모델의 목표는 **데이터의 실제 확률 분포 $p(x)$를 학습**하는 것이다. 이 분포를 알면 거기서 샘플링하여 새로운 데이터를 생성할 수 있다.

그러나 $p(x)$는 너무 복잡하여 직접 알 수 없으므로, 파라미터 θ를 가진 뉴럴넷으로 근사한다:

$$p_\theta(x) \approx p(x)$$

$p_\theta(x)$를 **데이터 라이클리후드(data likelihood)**라고 부른다.

1.2 생성 모델의 분류

분류	설명	예시
Explicit density estimation	확률 분포를 명시적으로 학습	VAE, Normalizing Flow, PixelCNN
Implicit density estimation	확률 분포를 암묵적으로 학습	GAN

VAE는 **explicit** 방식 중에서, 확률 분포를 **variational하게 근사**하는 모델이다.

---

2. Autoencoder 복습

2.1 구조

```
x → [Encoder] → z → [Decoder] → x̂
```

- **Encoder**: 입력 x (예: 256×256×3 이미지)를 저차원 벡터 z (예: 100차원)로 압축
- **Decoder**: z로부터 $\hat{x}$를 복원

2.2 손실 함수

(1) Gaussian Decoder — L2 Reconstruction Loss

각 픽셀 레벨에서 원본과 복원의 거리를 최소화한다:

$$\mathcal{L} = \frac{1}{N}\sum_{i=1}^{N} \|x_i - \hat{x}_i\|_2^2$$

컬러 이미지(RGB)에 대해 구체적으로 전개하면:

$$\mathcal{L} = \frac{1}{N}\sum_{i=1}^{m}\sum_{j=1}^{n}\sum_{k=1}^{3}(x_{ijk} - \hat{x}_{ijk})^2$$

여기서 $m \times n$은 이미지 해상도, $k \in \{R, G, B\}$는 채널이다.

(2) Bernoulli Decoder — Cross-Entropy Loss

픽셀값을 0~255의 **원핫 벡터**(256차원)로 표현한 뒤, cross-entropy loss를 적용한다:

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{m}\sum_{j=1}^{n}\sum_{k=1}^{3}\sum_{l=1}^{256} x_{ijkl} \log \hat{x}_{ijkl}$$

여기서 x_{ijkl}은 픽셀 (i, j)의 채널 k에서 값 l에 해당하는 원핫 인코딩 값이다.

> **VAE에서는 주로 Bernoulli Decoder(Cross-Entropy Loss)를 사용한다.**

2.3 오토인코더의 목적

오토인코더의 진짜 목표는 z**를 얻는 것** — 즉, 저차원 임베딩(low-dimensional representation)을 얻는 것이다.

- 디코더는 훈련용으로 붙인 것이고, 훈련 후에는 버린다
- PCA와 유사한 차원 축소이지만, 뉴럴넷의 비선형성 덕분에 **비선형 부분공간**으로 압축 가능

2.4 Manifold의 개념

매니폴드(Manifold): 데이터가 실제로 분포하는 저차원 공간

- 픽셀 스페이스: $256 \times 256 \times 3$차원, 각 픽셀이 256가지 값 → 경우의 수 천문학적
- 매니폴드: 훨씬 저차원 (예: 100차원 벡터)
- 예시: 공을 만들려면 반지름, 색깔, 조명 정도만 알면 된다 → 실제 필요한 정보는 훨씬 적다

2.5 Denoising Autoencoder

```
x → [노이즈 추가] → x' → [Encoder] → z → [Decoder] → x̂ (≈ 원본 x)
```

- 입력에 잡음을 추가한 x'을 인코더에 넣고, 디코더는 **잡음 추가 전 원본 x**를 복원
- 디코더가 잡음 제거(denoising) 능력까지 학습
- 이 개념은 후에 Diffusion Model 등에서 활용

---

3. AE vs VAE: 핵심 차이

	Autoencoder	VAE
잠재 공간	단순 벡터 매핑	확률 분포를 갖는 벡터 매핑
랜덤 값 입력 시	비현실적 노이즈 출력	그럴싸한 이미지 출력
생성 모델 여부	✗	✓

비유: 사람 키 분포(평균 175cm)를 알고 있으면 거기서 샘플링한 값은 현실적이지만, 아무 분포 없이 전체 공간에서 뽑으면 0cm, 1000cm 등 비현실적 값이 나온다.

4. VAE의 수학적 프레임워크

4.1 Bayes' Rule 복습

$$p(A \mid B) = \frac{p(B \mid A) \cdot p(A)}{p(B)}$$

항	이름	의미
$p(A \mid B)$	**Posterior**	사후 분포
$p(B \mid A)$	**Likelihood**	우도
$p(A)$	**Prior**	사전 분포 (미리 가정)
$p(B)$	**Evidence**	증거 (데이터로부터 추정)

4.2 VAE에서의 확률 분포 정의

Posterior (인코더가 배울 대상)

$$p_\theta(z \mid x): \quad x\text{가 주어졌을 때 } z\text{의 분포}$$

이것을 직접 계산할 수 없으므로 $q_\phi(z \mid x)$**로 근사**한다.

Likelihood (디코더가 배울 대상)

$$p_\theta(x \mid z): \quad z\text{가 주어졌을 때 } x\text{를 생성}$$

Prior (미리 가정)

$$p(z) = \mathcal{N}(0, I): \quad z\text{의 사전 분포를 표준 정규분포로 가정}$$

여기서 I는 항등 행렬(identity matrix)이다. z가 d차원이면 모든 방향으로 평균 0, 표준편차 1인 **등방성(isotropic) 가우시안**이다.

4.3 True Posterior가 계산 불가능한 이유

Bayes' rule로 풀어보면:

$$p_\theta(z \mid x) = \frac{p_\theta(x \mid z) \cdot p(z)}{p(x)}$$

문제는 분모 $p(x)$의 계산이다. Marginalization으로 시도하면:

$$p(x) = \int p_\theta(x \mid z) \cdot p(z)\, dz$$

이 적분은 모든 가능한 z에 대해 수행해야 한다.

예시로 이해하기 — 휴대폰 고장 확률 $p(x)$를 구하려면:

$$p(\text{고장}) = p(\text{고장}|\text{삼성}) \cdot p(\text{삼성}) + p(\text{고장}|\text{애플}) \cdot p(\text{애플}) + \cdots$$

이렇게 모든 브랜드에 대해 합산해야 하는데, z의 차원이 64~128차원이면 경우의 수가 **사실상 무한대**이다.

> **결론: $p(x)$를 계산하는 것은 intractable → $p_\theta(z \mid x)$도 직접 계산 불가 → 인코더 $q_\phi(z \mid x)$로 근사**

4.4 인코더의 출력 설계

인코더는 x를 입력받아 **가우시안 분포의 파라미터** μ, σ를 출력한다:

$$q_\phi(z \mid x) = \mathcal{N}(\mu(x), \sigma^2(x))$$

왜 바로 표준 정규분포를 출력하지 않는가?

만약 인코더가 모든 x에 대해 $\mathcal{N}(0, I)$를 출력한다면, 어떤 이미지를 넣어도 동일한 분포가 나온다. 이는 x에 의존적인 정보를 전혀 담지 못한다. 따라서:

- 훈련 시: x에 따라 달라지는 $\mu(x), \sigma(x)$를 출력하도록 학습
- 이 분포가 점차 표준 정규분포에 가까워지도록 **KL divergence로 규제**

---

5. ELBO 유도 — 전체 수식 전개

이 부분이 VAE의 핵심 수학이다. 단계별로 상세히 풀어본다.

Step 1: 출발점

우리의 목표는 데이터 라이클리후드를 maximize하는 것이다:

$$\max_\theta \ \log p_\theta(x)$$

Step 2: 1을 곱하는 트릭

확률 분포를 전체 적분하면 1이라는 성질을 이용한다:

$$\int q_\phi(z \mid x)\, dz = 1$$

따라서:

$$\log p_\theta(x) = \log p_\theta(x) \cdot \underbrace{\int q_\phi(z \mid x)\, dz}_{=1}$$

이 트릭으로 식 안에 없던 인코더 $q_\phi(z \mid x)$를 등장시킨다.

Step 3: 로그를 적분 안으로

$\log p_\theta(x)$는 z와 무관한 상수이므로 적분 안으로 넣을 수 있다:

$$= \int q_\phi(z \mid x) \cdot \log p_\theta(x)\, dz$$

Step 4: Bayes' rule 대입

$p_\theta(x)$를 Bayes' rule로 변환한다:

$$p_\theta(z \mid x) = \frac{p_\theta(x \mid z) \cdot p(z)}{p_\theta(x)}$$

이를 $p_\theta(x)$에 대해 정리하면:

$$p_\theta(x) = \frac{p_\theta(x \mid z) \cdot p(z)}{p_\theta(z \mid x)}$$

대입하면:

$$= \int q_\phi(z \mid x) \cdot \log \frac{p_\theta(x \mid z) \cdot p(z)}{p_\theta(z \mid x)} \, dz$$

Step 5: 분모·분자에 같은 항 곱하기

$\frac{q_\phi(z|x)}{q_\phi(z|x)} = 1$을 곱한다:

$$= \int q_\phi(z \mid x) \cdot \log \frac{p_\theta(x \mid z) \cdot p(z) \cdot q_\phi(z \mid x)}{p_\theta(z \mid x) \cdot q_\phi(z \mid x)} \, dz$$

Step 6: 로그의 곱을 합으로 분리

로그 안의 곱을 합으로 분해한다. 색깔별로 묶으면:

$$= \int q_\phi(z \mid x) \cdot \log p_\theta(x \mid z) \, dz \; - \; \int q_\phi(z \mid x) \cdot \log \frac{q_\phi(z \mid x)}{p(z)} \, dz \; + \; \int q_\phi(z \mid x) \cdot \log \frac{q_\phi(z \mid x)}{p_\theta(z \mid x)} \, dz$$

> **부호 주의**: 원래 분모에 있던 $\frac{p(z)}{q_\phi(z|x)}$를 분모·분자 뒤집으면 $\frac{q_\phi(z|x)}{p(z)}$가 되면서 부호가 $-$로 바뀐다.

Step 7: 각 항의 정체 파악

항 (A): Reconstruction Term

$$\int q_\phi(z \mid x) \cdot \log p_\theta(x \mid z) \, dz$$

이것은 기댓값의 정의 $\mathbb{E}_p[f] = \int p \cdot f$와 정확히 같다:

$$= \mathbb{E}_{q_\phi(z|x)} \left[\log p_\theta(x \mid z) \right]$$

해석: 인코더가 압축한 z로부터 디코더가 원본 x를 얼마나 잘 복원하는가 → **Reconstruction Loss**

항 (B): KL Divergence (인코더 ↔ Prior)

$$\int q_\phi(z \mid x) \cdot \log \frac{q_\phi(z \mid x)}{p(z)} \, dz$$

KL divergence의 정의 $D_{KL}(P \| Q) = \int P \log \frac{P}{Q}$와 정확히 같다:

$$= D_{KL}\big(q_\phi(z \mid x) \parallel p(z)\big)$$

해석: 인코더가 근사한 후방 분포가 사전 분포(표준 정규분포)와 얼마나 다른가 → **Regularization Term**

항 (C): KL Divergence (인코더 ↔ True Posterior)

$$\int q_\phi(z \mid x) \cdot \log \frac{q_\phi(z \mid x)}{p_\theta(z \mid x)} \, dz = D_{KL}\big(q_\phi(z \mid x) \parallel p_\theta(z \mid x)\big)$$

문제: $p_\theta(z \mid x)$는 true posterior로 **계산 불가능**. 그러나 KL divergence는 **항상 ≥ 0**이다.

Step 8: ELBO 도출

세 항을 합치면:

$$\log p_\theta(x) = \underbrace{\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x \mid z)] - D_{KL}(q_\phi(z \mid x) \| p(z))}_{\text{ELBO (Evidence Lower Bound)}} + \underbrace{D_{KL}(q_\phi(z \mid x) \| p_\theta(z \mid x))}_{\geq 0}$$

세 번째 항이 ≥ 0이므로:

$$\boxed{\log p_\theta(x) \geq \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x \mid z)] - D_{KL}(q_\phi(z \mid x) \| p(z))}$$

우변을 **ELBO**라고 부르며, $\log p_\theta(x)$를 직접 maximize할 수 없으므로 대신 ELBO를 maximize한다.

---

6. 손실 함수의 구체적 계산

6.1 부호 반전: Maximize → Minimize

경사 하강법을 사용하기 위해 부호를 뒤집는다:

$$\mathcal{L}(\theta, \phi; x) = -\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x \mid z)] + D_{KL}(q_\phi(z \mid x) \| p(z))$$

이것이 VAE의 **최종 손실 함수**이다:

$$\mathcal{L} = \underbrace{-\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x \mid z)]}_{\text{Reconstruction Loss}} + \underbrace{D_{KL}(q_\phi(z \mid x) \| p(z))}_{\text{Regularization Term}}$$

6.2 Reconstruction Term 계산 (Bernoulli Decoder)

Bernoulli decoder를 가정하면, $\log p_\theta(x \mid z)$는 cross-entropy로 계산된다:

$$-\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x \mid z)] \approx -\sum_{i,j,k,l} x_{ijkl} \log \hat{x}_{ijkl}$$

> **Monte Carlo 근사**: 기댓값을 정확히 계산하는 것은 비용이 너무 크다. 따라서 **샘플 1개**만 뽑아서 대표값으로 사용한다 (논문에서 $L = 1$).

6.3 KL Divergence Term 계산 (두 가우시안 사이)

두 분포:

- $q_\phi(z \mid x) = \mathcal{N}(\mu, \sigma^2 I)$ (인코더 출력)
- $p(z) = \mathcal{N}(0, I)$ (표준 정규분포)

두 가우시안 간의 KL divergence는 해석적 closed-form이 존재한다.

유도 과정

1차원 경우를 먼저 유도한다. $q = \mathcal{N}(\mu, \sigma^2)$, $p = \mathcal{N}(0, 1)$일 때:

$$D_{KL}(q\|p) = \int q(z) \log \frac{q(z)}{p(z)} dz$$

가우시안의 확률밀도함수를 대입한다:

$$q(z) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(z-\mu)^2}{2\sigma^2}\right)$$

$$p(z) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right)$$

로그 비율을 계산하면:

$$\begin{aligned}\log \frac{q(z)}{p(z)} &= \log \frac{1/\sqrt{2\pi\sigma^2}}{1/\sqrt{2\pi}} + \left(-\frac{(z-\mu)^2}{2\sigma^2} + \frac{z^2}{2}\right) \\ &= -\frac{1}{2}\log\sigma^2 - \frac{(z-\mu)^2}{2\sigma^2} + \frac{z^2}{2}\end{aligned}$$

$q(z)$에 대한 기댓값을 취한다:

$$D_{KL} = \mathbb{E}_q\left[-\frac{1}{2}\log\sigma^2 - \frac{(z-\mu)^2}{2\sigma^2} + \frac{z^2}{2}\right]$$

각 항을 따로 계산한다:

- $\mathbb{E}_q\left[-\frac{1}{2}\log\sigma^2\right] = -\frac{1}{2}\log\sigma^2$ (상수)
- $\mathbb{E}_q\left[-\frac{(z-\mu)^2}{2\sigma^2}\right] = -\frac{1}{2\sigma^2} \cdot \sigma^2 = -\frac{1}{2}$ ($\because \mathbb{E}[(z-\mu)^2] = \sigma^2$)
- $\mathbb{E}_q\left[\frac{z^2}{2}\right] = \frac{1}{2}(\mu^2 + \sigma^2)$ ($\because \mathbb{E}[z^2] = \mathrm{Var}(z) + (\mathbb{E}[z])^2 = \sigma^2 + \mu^2$)

합산하면:

$$\begin{aligned}D_{KL} &= -\frac{1}{2}\log\sigma^2 - \frac{1}{2} + \frac{1}{2}(\mu^2 + \sigma^2) \\ &= -\frac{1}{2}\left(\log\sigma^2 + 1 - \mu^2 - \sigma^2\right) \\ &= -\frac{1}{2}\left(1 + \log\sigma^2 - \mu^2 - \sigma^2\right)\end{aligned}$$

d차원 벡터로 확장하면 (각 차원이 독립이므로 합산):

$$\boxed{D_{KL}(q_\phi(z \mid x)\|p(z)) = -\frac{1}{2}\sum_{j=1}^{d}\left(1 + \log\sigma_j^2 - \mu_j^2 - \sigma_j^2\right)}$$

6.4 최종 손실 함수 (실제 구현)

$$\boxed{\mathcal{L} = -\sum_{i,j,k,l} x_{ijkl} \log \hat{x}_{ijkl} \;-\; \frac{1}{2}\sum_{j=1}^{d}\left(1 + \log\sigma_j^2 - \mu_j^2 - \sigma_j^2\right)}$$

---

7. Reparameterization Trick

문제

인코더가 μ, σ를 출력한 뒤 $z \sim \mathcal{N}(\mu, \sigma^2)$에서 샘플링해야 하는데, "샘플링"은 미분 불가능한 연산이다. 역전파(backpropagation)가 끊긴다.

해결

확률적 연산을 결정적 연산으로 변환한다:

$$\epsilon \sim \mathcal{N}(0, I)$$

$$z = \mu + \sigma \odot \epsilon$$

여기서 $\odot$은 원소별 곱(element-wise product)이다.

왜 이것이 동치인가?

확률변수 $\epsilon \sim \mathcal{N}(0, 1)$에 대해:

- $\sigma \cdot \epsilon \sim \mathcal{N}(0, \sigma^2)$
- $\mu + \sigma \cdot \epsilon \sim \mathcal{N}(\mu, \sigma^2)$

따라서 $z = \mu + \sigma \odot \epsilon$은 $\mathcal{N}(\mu, \sigma^2)$에서 샘플링한 것과 동일하다.

이제 μ, σ에 대한 미분이 가능하므로 역전파가 작동한다. ϵ은 외부에서 주입되는 노이즈로 취급되어 그래디언트 경로에 영향을 주지 않는다.

---

8. 전체 파이프라인

훈련 시

```
x → Encoder → μ, σ
                ↓
        ε ~ N(0,I)
                ↓
        z = μ + σ⊙ε → Decoder → x̂
                                ↓
                    Loss = Reconstruction + KL
```

1. 이미지 x를 인코더에 입력
2. 인코더가 μ, σ 출력
3. Reparameterization trick: $z = \mu + \sigma \odot \epsilon$
4. z를 디코더에 입력, $\hat{x}$ 복원
5. $\mathcal{L} = \text{Reconstruction Loss} + \text{KL Divergence}$ 계산 후 minimize

생성 시

인코더는 버리고 디코더만 사용:

```
ε ~ N(0,I) → z → Decoder → 새 이미지
```

1. 표준 정규분포에서 z 샘플링
2. z를 디코더에 입력
3. 이미지 생성

> 훈련 때 인코더가 데이터를 표준 정규분포에 가깝게 압축하도록 학습했기 때문에, 표준 정규분포에서 뽑은 아무 값이든 그럴싸한 이미지가 생성된다.

---

9. Posterior Collapse 문제

현상

Regularization term(KL divergence)이 너무 강하게 작용하면:

$$D_{KL}(q_\phi(z \mid x) \| p(z)) \to 0$$

이 경우 인코더가 모든 x에 대해 $q_\phi(z \mid x) \approx \mathcal{N}(0, I)$를 출력하게 되어, 입력 x와 무관한 분포를 내놓는다.

결과

- 인코더가 데이터를 의미 있게 압축하지 못함
- 디코더에 지나치게 의존 → 평균적인(blurry) 이미지만 생성
- 잠재 공간이 무의미해짐

비유

KL 항에 큰 계수(예: ×10000)를 곱하면, 모델은 reconstruction보다 KL을 줄이는 데 집중한다. 극단적으로, 인코더 없이 표준 정규분포에서 바로 샘플링하는 것과 다를 바 없어진다.

---

10. Latent Space의 구조적 성질

학습된 잠재 공간은 **연속적(continuous)이고 구조적(structured)**인 의미를 가진다:

- z를 특정 축 방향으로 연속적으로 변화시키면 생성 이미지도 부드럽게 변환
  - MNIST: 6 → 0, 8 → 9 등으로 서서히 전환
  - 얼굴: 시선 방향, 표정(무표정 → 웃음) 등이 연속적으로 변화
- **Concept vector**: "웃음 벡터", "시선 벡터" 등을 찾아서 생성 이미지를 컨트롤 가능

이러한 성질은 **확률 분포를 학습했기 때문에** 가능하다.

---

11. VAE 요약

장점

- **Principled generative model**: 데이터 라이클리후드를 이론적으로 maximize

- 잠재 공간에서 z 값을 조절하며 이미지를 컨트롤 가능
- 인코더의 압축 능력이 뛰어남 → 후속 모델(VQ-VAE, Stable Diffusion 등)에서 널리 활용

단점

- ELBO를 maximize하는 것이지 true likelihood를 직접 maximize하는 것이 아님 (unknown term 존재)
- 생성 이미지가 **blurry** (윤곽선이 선명하지 않음)
- Posterior collapse 문제

논문 저자의 insight

> "복잡한 prior가 필요한 것 아니냐?"
> → 딥 뉴럴넷인 디코더의 앞쪽 레이어들이 확률 분포의 복잡한 부분을 학습하기 때문에, 단순한 표준 정규분포 prior로도 충분하다.

후속 발전

- **VQ-VAE**: 이산적 코드북을 이용한 양자화 버전
- **DALL-E, Stable Diffusion**: VAE 구조를 핵심 컴포넌트로 활용

저자: Kingma & Welling, 2013 (Auto-Encoding Variational Bayes)
Kingma는 Adam Optimizer의 저자이기도 하다.