생성 모델을 위한 수학적 기반 지식 — Transformer와의 비교 포함

> 이 문서는 생성 모델(VAE ~ Flow Matching)을 이해하기 위해 필요한 수학적 기반 지식을 정리한다.
>
> Transformer와 비교하여 "어디서부터 추가로 필요한가"를 명확히 한다.

0. Transformer vs 생성 모델: 수학적 요구사항 비교

0.1 한눈에 보기

수학 영역	Transformer	VAE / GAN	DDPM	Flow Matching	SDE 통합
선형대수 (행렬, 고유값)	★★★ 핵심	★★	★★	★★	★★
미적분 (편미분, 기울기)	★★	★★	★★★	★★★	★★★
확률론 (조건부, 베이즈)	★★	★★★ 핵심	★★★ 핵심	★★★	★★★
정보이론 (KL, Entropy)	★	★★★ 핵심	★★★	★★	★★★
다변량 가우시안	★	★★★ 핵심	★★★ 핵심	★★★	★★★
미분방정식 (ODE)	—	—	★ (DDIM)	★★★ 핵심	★★★ 핵심
확률 미분방정식 (SDE)	—	—	★	★★	★★★ 핵심
벡터 해석 (발산, 연속 방정식)	—	—	—	★★	★★★
최적 수송 (OT)	—	—	—	★★	★★
변분법 (ELBO)	—	★★★ 핵심	★★	—	★★
마르코프 체인	—	—	★★★ 핵심	—	★★
측도론	—	—	—	★	★★ (깊이 파려면)

0.2 핵심 차이

Transformer: "행렬 곱셈의 기하학"이 핵심. $QK^\top/\sqrt{d}$, softmax, 역전파만 알면 된다.

생성 모델: "확률 분포의 변환"이 핵심. $p(x)$라는 알 수 없는 분포를 모델링하고, 분포 사이의 거리를 재고, 한 분포에서 다른 분포로 변환하는 방법을 배운다. 이 과정에서 확률론, 미분방정식, 정보이론이 모두 엮인다.

Transformer를 공부할 때는 "이 수식이 왜 이렇게 생겼지?"가 대부분 직관적으로 해결되지만, Diffusion/Flow Matching은 수식 유도 자체를 따라가려면 수학적 도구가 필요하다.

0.3 좋은 소식

MIT 6.S184 (Flow Matching & Diffusion) 강의의 공식 선수과목은 **선형대수 + 다변량 미적분 + 기초 확률론**뿐이다. 나머지(ODE, SDE, Fokker-Planck 등)는 강의 안에서 가르친다. 즉, 아래 내용을 완벽하게 마스터한 뒤에 생성 모델을 시작하는 것이 아니라, **필요할 때 돌아와서 참조하는 레퍼런스**로 활용하면 된다.

---

1. 확률론 기초 (Transformer에서도 쓰지만 더 깊이 필요)

1.1 이미 아는 것 (Transformer 수준)

- 확률 변수, 기댓값, 분산
- Softmax = 확률 분포화
- Cross-Entropy Loss = $-\sum y_i \log \hat{y}_i$

1.2 생성 모델에서 추가로 필요한 것

(1) 조건부 확률과 베이즈 정리 — 모든 곳에서

$$p(z \mid x) = \frac{p(x \mid z)\, p(z)}{p(x)}$$

요소	이름	생성 모델에서의 역할
$p(z\|x)$	사후 분포 (Posterior)	VAE의 인코더, DDPM의 역과정 $q(x_{t-1}\|x_t, x_0)$
$p(x\|z)$	우도 (Likelihood)	VAE의 디코더, "이 잠재 변수에서 이미지가 나올 확률"
$p(z)$	사전 분포 (Prior)	$\mathcal{N}(0, I)$, 우리가 가정하는 간단한 분포
$p(x)$	증거 (Evidence)	$\int p(x\|z)p(z)dz$, **계산 불가능** → 이것 때문에 ELBO가 필요

> **핵심**: 생성 모델의 거의 모든 수식은 $p(x) = \int p(x \mid z)p(z)dz$가 계산 불가능하다는 문제에서 출발한다.

(2) 주변화 (Marginalization)

$$p(x) = \int p(x, z)\, dz = \int p(x \mid z)\, p(z)\, dz$$

잠재 변수 z를 "적분으로 제거"하여 관측 변수 x만의 분포를 구하는 것. 고차원에서 이 적분이 계산 불가능하므로 VAE는 ELBO로 우회하고, GAN은 아예 $p(x)$를 명시적으로 구하지 않는다.

(3) 기댓값의 다양한 표현

$$\mathbb{E}_{x \sim p}[f(x)] = \int f(x)\, p(x)\, dx$$

생성 모델 논문에서 매우 자주 나오는 표기:

- $\mathbb{E}_{q(z|x)}[\cdot]$ — $q(z \mid x)$에서 z를 샘플링하여 평균
- $\mathbb{E}_{t \sim U[0,T]}[\cdot]$ — 타임스텝을 균등 분포에서 랜덤 선택
- $\mathbb{E}_{x_0, \epsilon}[\cdot]$ — 데이터와 노이즈 모두에 대해 평균

DDPM의 학습 목표가 바로 이런 형태:

$$\mathcal{L} = \mathbb{E}_{t, x_0, \epsilon}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|^2\right]$$

(4) 확률 변수의 변환 (Change of Variables)

확률 변수 X에 함수 $Y = g(X)$를 적용하면 분포가 어떻게 바뀌는가?

1차원:

$$p_Y(y) = p_X(g^{-1}(y)) \cdot \left|\frac{dg^{-1}}{dy}\right|$$

다차원 (Normalizing Flow의 핵심):

$$p_Y(\mathbf{y}) = p_X(g^{-1}(\mathbf{y})) \cdot \left|\det \frac{\partial g^{-1}}{\partial \mathbf{y}}\right|$$

어디서 쓰는가	수식
Normalizing Flow	가역 변환의 체인을 통해 $p(x)$를 명시적으로 계산
VAE	Reparameterization Trick의 이론적 배경
Flow Matching	CNF에서 $\log p_t(x)$의 변화를 추적

---

2. 다변량 가우시안 분포 (생성 모델의 만능 도구)

2.1 왜 가우시안이 이렇게 중요한가?

거의 모든 생성 모델이 가우시안을 사용한다:

- **VAE**: $p(z) = \mathcal{N}(0, I)$, $q(z \mid x) = \mathcal{N}(\mu, \sigma^2 I)$

- **DDPM**: Forward process가 가우시안 노이즈 추가, Reverse도 가우시안
- **Flow Matching**: $p_{\text{init}} = \mathcal{N}(0, I)$에서 시작
- **Langevin Dynamics**: 노이즈 항이 가우시안

2.2 핵심 성질들

정의:

$$\mathcal{N}(x; \mu, \Sigma) = \frac{1}{\sqrt{(2\pi)^d |\Sigma|}} \exp\left(-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)\right)$$

반드시 알아야 할 성질:

성질	수식	어디서 쓰는가
아핀 변환	$X \sim \mathcal{N}(\mu, \Sigma)$이면 $AX + b \sim \mathcal{N}(A\mu + b, A\Sigma A^\top)$	Reparameterization, Forward process
두 가우시안의 합	$X + Y \sim \mathcal{N}(\mu_X + \mu_Y, \Sigma_X + \Sigma_Y)$ (독립일 때)	DDPM closed-form 유도
가우시안 곱	$\mathcal{N}(\mu_1, \sigma_1^2) \cdot \mathcal{N}(\mu_2, \sigma_2^2) \propto \mathcal{N}(\tilde{\mu}, \tilde{\sigma}^2)$	DDPM 역과정 posterior 유도
조건부 가우시안	Joint가 가우시안이면 조건부도 가우시안	거의 모든 Diffusion 수식
KL between 가우시안	아래 Section 3 참조	VAE 학습, DDPM ELBO

Reparameterization Trick (VAE, DDPM 모두 사용)

$z \sim \mathcal{N}(\mu, \sigma^2 I)$에서 직접 샘플링하면 역전파가 불가능.

대신: $z = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$

이렇게 하면 μ, σ에 대한 기울기를 ϵ을 통해 계산할 수 있다.

DDPM에서도 동일한 원리:

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1 - \bar{\alpha}_t}\, \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

가우시안 곱 (DDPM Posterior 유도의 핵심)

두 가우시안의 곱은 다시 가우시안 (비정규화):

$$\mathcal{N}(x; \mu_1, \sigma_1^2) \cdot \mathcal{N}(x; \mu_2, \sigma_2^2) \propto \mathcal{N}\left(x;\ \frac{\sigma_2^2 \mu_1 + \sigma_1^2 \mu_2}{\sigma_1^2 + \sigma_2^2},\ \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2}\right)$$

이 성질이 DDPM의 $q(x_{t-1} \mid x_t, x_0)$를 닫힌 형태로 구할 때 핵심적으로 사용된다:

$$q(x_{t-1} \mid x_t, x_0) \propto q(x_t \mid x_{t-1}) \cdot q(x_{t-1} \mid x_0)$$

두 가우시안의 곱 → 결과도 가우시안 → $\tilde{\mu}_t$, $\tilde{\beta}_t$ 도출.

---

3. 정보이론 (KL Divergence, Entropy, ELBO)

3.1 Transformer에서의 정보이론

Cross-Entropy Loss 정도만 사용:

$$H(p, q) = -\sum_x p(x) \log q(x)$$

3.2 생성 모델에서의 정보이론

(1) KL Divergence — 가장 중요한 거리 척도

$$D_{\mathrm{KL}}(q \| p) = \mathbb{E}_{x \sim q}\left[\log \frac{q(x)}{p(x)}\right] = \int q(x) \log \frac{q(x)}{p(x)} dx$$

성질	의미
$D_{\mathrm{KL}} \geq 0$	항상 0 이상 (Gibbs' inequality)
$D_{\mathrm{KL}}(q \| p) = 0 \iff q = p$	동일 분포일 때만 0
비대칭: $D_{\mathrm{KL}}(q \| p) \neq D_{\mathrm{KL}}(p \| q)$	Forward KL vs Reverse KL이 다른 행동

두 가우시안 사이의 KL (VAE 학습에서 매 배치 계산):

$$D_{\mathrm{KL}}(\mathcal{N}(\mu, \sigma^2) \| \mathcal{N}(0, 1)) = \frac{1}{2}\left(\mu^2 + \sigma^2 - \log \sigma^2 - 1\right)$$

다변량 버전:

$$D_{\mathrm{KL}}(\mathcal{N}(\mu, \Sigma) \| \mathcal{N}(0, I)) = \frac{1}{2}\left(\mathrm{tr}(\Sigma) + \mu^\top \mu - d - \log |\Sigma|\right)$$

> VAE의 $\mathcal{L}_{\mathrm{KL}}$ 항이 바로 이것. 이 수식을 알면 VAE 코드의 KL 계산 부분이 바로 이해된다.

(2) ELBO (Evidence Lower Bound) — VAE의 핵심

$\log p(x)$를 직접 최대화하고 싶지만 불가능. 대신 하한을 최대화:

$$\log p(x) \geq \underbrace{\mathbb{E}_{q(z|x)}[\log p(x \mid z)]}_{\text{복원 항}} - \underbrace{D_{\mathrm{KL}}(q(z \mid x) \| p(z))}_{\text{정규화 항}} = \mathrm{ELBO}$$

유도:

$$\log p(x) = \log \int p(x \mid z) p(z) dz$$

$$= \log \int \frac{p(x \mid z) p(z)}{q(z \mid x)} q(z \mid x) dz$$

$$= \log \mathbb{E}_{q(z|x)} \left[\frac{p(x \mid z)p(z)}{q(z \mid x)} \right]$$

$$\geq \mathbb{E}_{q(z|x)} \left[\log \frac{p(x \mid z)p(z)}{q(z \mid x)} \right] \quad \text{(Jensen's inequality)}$$

$$= \mathbb{E}_{q(z|x)}[\log p(x \mid z)] - D_{\mathrm{KL}}(q(z \mid x) \| p(z))$$

> **DDPM도 같은 구조.** DDPM의 variational bound도 ELBO의 확장이며, 각 타임스텝에서의 KL 합으로 분해된다.

(3) Fisher Divergence — Score Matching의 기반

$$D_F(p \| q) = \mathbb{E}_{x \sim p} \left[\| \nabla_x \log p(x) - \nabla_x \log q(x) \|^2 \right]$$

Score Function(기울기) 사이의 거리. KL과 달리 $p(x)$의 정규화 상수 Z가 필요 없다. Score-Based Model의 학습 목표:

$$\mathcal{L} = \mathbb{E}_{x \sim p_{\text{data}}} \left[\| s_\theta(x) - \nabla_x \log p_{\text{data}}(x) \|^2 \right]$$

---

4. 미적분 심화 (기울기, 야코비안, 발산)

4.1 Transformer에서의 미적분

- 역전파 = 연쇄 법칙 (Chain Rule)
- Softmax의 미분
- 대부분 프레임워크(PyTorch)가 자동 처리

4.2 생성 모델에서 추가로 필요한 것

(1) 기울기 (Gradient) — Score Function의 정체

스칼라 함수 $f : \mathbb{R}^d \to \mathbb{R}$의 기울기:

$$\nabla_x f(x) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \ldots, \frac{\partial f}{\partial x_d} \right)$$

Score Function:

$$s(x) = \nabla_x \log p(x)$$

직관: 확률이 높은 방향을 가리키는 벡터. Langevin Dynamics는 이 벡터를 따라가면서 고확률 영역으로 이동한다.

가우시안 $p(x) = \mathcal{N}(\mu, \sigma^2)$의 스코어:

$$\nabla_x \log p(x) = -\frac{x - \mu}{\sigma^2}$$

→ 평균 μ를 향한 "당기는 힘". x가 μ에서 멀수록 강하게 당긴다.

(2) 야코비안 (Jacobian) — Normalizing Flow의 핵심

벡터 함수 $f : \mathbb{R}^d \to \mathbb{R}^d$의 야코비안:

$$J_f(x) = \frac{\partial f}{\partial x} = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_d} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_d}{\partial x_1} & \cdots & \frac{\partial f_d}{\partial x_d} \end{pmatrix}$$

Normalizing Flow의 Change of Variables:

$$\log p(y) = \log p(x) - \log |\det J_f(x)|$$

야코비안의 행렬식 = 변환이 부피를 얼마나 늘리거나 줄이는지.

> Normalizing Flow 모델들(RealNVP, Glow)이 삼각 야코비안을 사용하는 이유: $\det$를 $O(d)$로 계산하기 위해.

(3) 발산 (Divergence) — 연속 방정식, Fokker-Planck

벡터장 $v : \mathbb{R}^d \to \mathbb{R}^d$의 발산:

$$\nabla \cdot v = \frac{\partial v_1}{\partial x_1} + \frac{\partial v_2}{\partial x_2} + \cdots + \frac{\partial v_d}{\partial x_d} = \mathrm{tr}(J_v)$$

직관: 해당 점에서 "흐름이 퍼져나가는 정도". 양수면 발산(source), 음수면 수렴(sink).

연속 방정식 (Flow Matching의 이론적 기반):

$$\frac{\partial p_t}{\partial t} + \nabla \cdot (p_t \, v_t) = 0$$

의미: 확률 질량은 보존된다. 물이 흘러가면 어딘가에서 줄고 어딘가에서 늘지만, 총량은 같다.

Fokker-Planck 방정식 (SDE 통합 프레임워크의 핵심):

$$\frac{\partial p_t}{\partial t} = -\nabla \cdot (f \, p_t) + \frac{1}{2} \nabla^2 \cdot (g^2 p_t)$$

연속 방정식에 확산(diffusion) 항 $\frac{1}{2} g^2 \nabla^2 p_t$가 추가된 것. 이것이 SDE의 확률 밀도가 시간에 따라 어떻게 변하는지를 기술한다.

(4) 라플라시안 (Laplacian) — 확산의 수학

$$\nabla^2 f = \sum_{i=1}^{d} \frac{\partial^2 f}{\partial x_i^2}$$

열 방정식(Heat Equation) $\frac{\partial u}{\partial t} = \alpha \nabla^2 u$의 핵심 연산자.

"Diffusion"이라는 이름 자체가 여기서 온 것: DDPM의 Forward Process는 **물리적 확산 과정**과 수학적으로 동일하다.

---

5. 미분방정식 (ODE / SDE)

5.1 Transformer에서는 전혀 불필요

Transformer에는 미분방정식이 등장하지 않는다. (Neural ODE를 쓰지 않는 한.)

5.2 생성 모델에서 필수인 이유

모델	미분방정식	역할
DDIM	ODE (확률 흐름)	결정론적 빠른 샘플링
Flow Matching	ODE	속도장 v_θ를 따라 노이즈→데이터 변환
DDPM	이산 마르코프 체인 (연속 극한 → SDE)	노이즈 추가/제거
Yang Song 통합	SDE + ODE (Probability Flow)	Score-Based와 DDPM의 이론적 통합

(1) 상미분방정식 (ODE) — Flow Matching의 기반

$$\frac{dx_t}{dt} = v(x_t, t)$$

- $v(x_t, t)$: **속도장** (velocity field). 시간 t, 위치 x_t에서의 속도.
- 해(solution): 궤적(trajectory) $x_t = \phi_t(x_0)$ — **Flow**라고 부른다.

수치적 해법: Euler 방법

$$x_{t+h} \approx x_t + h \cdot v(x_t, t)$$

작은 시간 스텝 h만큼 속도 방향으로 이동. Flow Matching에서의 생성(샘플링)이 바로 이것:

```
# Flow Matching 샘플링 (Euler method)
x = torch.randn(batch, dim)  # x_0 ~ N(0, I)
for t in torch.linspace(0, 1, steps):
    v = model(x, t)           # 속도장 예측
    x = x + (1/steps) * v     # Euler step
# x가 생성된 이미지
```

(2) 확률 미분방정식 (SDE) — Diffusion의 수학적 표현

$$dX_t = f(X_t, t)\,dt + g(t)\,dW_t$$

항	이름	의미
$f(X_t, t)\,dt$	**드리프트** (Drift)	결정론적 방향 (ODE 부분)
$g(t)\,dW_t$	**확산** (Diffusion)	확률적 노이즈 (브라운 운동)

W_t	**브라운 운동** (Brownian Motion)	연속적 랜덤 워크

> **핵심**: ODE = SDE에서 $g(t) = 0$인 특수한 경우. Flow Matching(ODE)과 Diffusion(SDE)은 이 하나의 차이.

수치적 해법: Euler-Maruyama

$$X_{t+h} \approx X_t + h \cdot f(X_t, t) + g(t)\sqrt{h} \cdot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

Euler 방법 + 가우시안 노이즈 항 추가. DDPM의 샘플링 알고리즘이 실질적으로 이것:

```
# DDPM 샘플링 (Euler-Maruyama와 동등)
x = torch.randn(batch, dim)  # x_T ~ N(0, I)
for t in reversed(range(T)):
    eps_pred = model(x, t)    # 노이즈 예측
    x = (1/sqrt(α_t)) * (x - β_t/sqrt(1-ᾱ_t) * eps_pred) + sqrt(β̃_t) * z
    #    └──────── 드리프트 (결정론적) ──────────┘   └── 확산 (확률적) ──┘
```

(3) 브라운 운동 (Brownian Motion)

수학적 정의:

- $W_0 = 0$
- 경로 $t \mapsto W_t$는 연속
- $W_t - W_s \sim \mathcal{N}(0, (t-s)I)$ (독립 증분)

직관: 매 순간 가우시안 노이즈만큼 무작위로 움직이는 점. "연속적 랜덤 워크."

Diffusion Model에서의 역할: Forward Process에서 이미지에 점진적으로 노이즈를 추가하는 것이 브라운 운동을 따르는 것과 수학적으로 동일.

(4) Ornstein-Uhlenbeck (OU) Process

$$dX_t = -\theta X_t \, dt + \sigma \, dW_t$$

- $-\theta X_t$: 원점으로 당기는 힘 (mean-reverting)
- $\sigma \, dW_t$: 무작위 흔들림

정상 분포(stationary distribution): $\mathcal{N}(0, \sigma^2/(2\theta))$

> DDPM의 Forward Process는 OU Process의 이산 버전이다. $-\theta X_t$가 이미지를 0으로 당기고, σdW_t가 노이즈를 추가한다. 충분히 오래 돌리면 $\mathcal{N}(0, I)$에 수렴.

---

6. 마르코프 체인과 확률 과정

6.1 마르코프 성질 — DDPM의 핵심 가정

$$p(x_t \mid x_{t-1}, x_{t-2}, \ldots, x_0) = p(x_t \mid x_{t-1})$$

미래는 **현재에만 의존**, 과거에는 의존하지 않는다.

DDPM의 Forward Process:

$$q(x_{1:T} \mid x_0) = \prod_{t=1}^{T} q(x_t \mid x_{t-1})$$

각 스텝이 이전 스텝에만 의존 → 마르코프 체인.

6.2 왜 마르코프 가정이 유용한가?

1. **계산이 가능해진다**: Joint 분포를 조건부 분포의 곱으로 분해
2. $q(x_t \mid x_0)$**의 닫힌 형태**: 마르코프 체인 + 가우시안 → 어떤 t에서든 한 번에 계산 가능
3. **역과정 학습**: $q(x_{t-1} \mid x_t, x_0)$가 가우시안으로 닫힘

---

7. 최적 수송 (Optimal Transport)

7.1 기본 아이디어

"흙더미 P를 구멍 Q에 채우는 최소 비용 방법은?"

$$W_2(P, Q) = \left(\inf_{\pi \in \Pi(P,Q)} \int \|x - y\|^2 \, d\pi(x, y) \right)^{1/2}$$

- π: **운반 계획** (어떤 x를 어떤 y로 보낼지)
- $\Pi(P, Q)$: 주변 분포가 P, Q인 모든 결합 분포의 집합
- W_2: **Wasserstein-2 거리** (= Earth Mover's Distance)

7.2 KL Divergence vs Wasserstein 거리

	KL Divergence	**Wasserstein 거리**
대칭성	❌ 비대칭	✅ 대칭
겹치지 않는 분포	∞	유한한 값
직관	"정보적 거리"	"물리적 이동 거리"
사용 모델	VAE, DDPM	WGAN, Flow Matching

> KL의 치명적 문제: 두 분포가 겹치지 않으면(support가 다르면) ∞. 하지만 Wasserstein은 "얼마나 떨어져 있는지"를 잴 수 있다. 이것이 WGAN의 동기였고, Flow Matching이 Optimal Transport 경로를 사용하는 이유이기도 하다.

7.3 Flow Matching에서의 OT 경로

Flow Matching의 Optimal Transport displacement interpolation:

$$\psi_t(x_0 \mid x_1) = (1-t)x_0 + tx_1$$

이것이 **Wasserstein 측지선**(geodesic)이다: 노이즈 x_0에서 데이터 x_1까지의 가장 효율적인 직선 경로.

Diffusion의 구불구불한 SDE 경로 vs Flow Matching의 직선 OT 경로 → 후자가 더 적은 스텝으로 도달.

7.4 어디까지 알아야 하는가?

수준	내용	필요 시점
직관	흙더미 비유, Wasserstein = 이동 비용	WGAN, Flow Matching 이해
기본 수식	W_2 정의, 1D에서의 해	Flow Matching 논문 읽기
이론	Brenier 정리, Kantorovich 쌍대성	OT 기반 연구를 직접 할 때

대부분의 경우 직관 수준이면 충분하다.

---

8. 변분 추론 (Variational Inference)

8.1 핵심 아이디어

계산 불가능한 $p(z \mid x)$ 대신, 학습 가능한 $q_\phi(z \mid x)$로 근사:

$$q_\phi(z \mid x) \approx p(z \mid x)$$

"최적화 문제로 전환": $D_{\mathrm{KL}}(q_\phi(z \mid x) \| p(z \mid x))$를 최소화.

8.2 ELBO의 또 다른 유도 (KL 관점)

$$D_{\mathrm{KL}}(q(z \mid x) \| p(z \mid x)) = \log p(x) - \mathrm{ELBO}$$

$D_{\mathrm{KL}} \geq 0$이므로:

$$\mathrm{ELBO} \leq \log p(x)$$

ELBO를 최대화하면 동시에:

1. $\log p(x)$의 좋은 하한을 얻고
2. $q(z \mid x)$가 진짜 $p(z \mid x)$에 가까워진다

8.3 DDPM에서의 변분 추론

DDPM도 사실 "1000-레이어 VAE"로 볼 수 있다:

$$\log p(x_0) \geq \mathrm{ELBO} = \mathbb{E}_q \left[\log \frac{p(x_{0:T})}{q(x_{1:T} \mid x_0)} \right]$$

이를 분해하면 각 타임스텝에서의 KL Divergence 합:

$$= \underbrace{-D_{\mathrm{KL}}(q(x_T \mid x_0) \| p(x_T))}_{\text{Prior matching}} + \sum_{t=2}^{T} \underbrace{-D_{\mathrm{KL}}(q(x_{t-1} \mid x_t, x_0) \| p_\theta(x_{t-1} \mid x_t))}_{\text{각 스텝의 역과정 학습}} + \underbrace{\log p_\theta(x_0 \mid x_1)}_{\text{복원}}$$

Ho et al. (2020)이 보여준 것: 이 복잡한 ELBO가 결국 단순한 Simple Loss $\|\epsilon - \epsilon_\theta\|^2$로 귀결된다.

---

9. 학습 우선순위: 무엇을 먼저, 얼마나 깊이?

9.1 Tier 1: 반드시 먼저 (생성 모델 시작 전)

주제	수준	학습 시간	핵심 내용
다변량 가우시안	수식 유도 가능	2~3일	밀도 함수, 아핀 변환, 곱, 조건부
KL Divergence	정의 + 가우시안 KL 유도	1~2일	비대칭성, 두 가우시안 KL 공식
베이즈 정리 & 조건부 확률	직관 + 계산	1일	Prior, Posterior, Likelihood, Evidence
기댓값 & 적분	기호 읽기 + 계산	1일	$\mathbb{E}_{x\sim p}[f(x)]$의 다양한 표기

> **이것만 있으면**: VAE, GAN, DDPM의 수식을 읽고 이해할 수 있다.

9.2 Tier 2: 병행하면서 (DDPM/LDM 학습과 함께)

주제	수준	학습 시간	핵심 내용
ELBO 유도	Jensen 부등식부터 유도	2~3일	VAE → DDPM ELBO로 확장
마르코프 체인	정의 + 성질	1일	DDPM Forward/Reverse 이해
기울기 & Score Function	다변량 기울기 계산	1~2일	$\nabla_x \log p(x)$의 직관
기본 ODE	Euler 방법으로 풀기	2일	$dx/dt = f(x,t)$, 수치 시뮬레이션
Change of Variables	1D → 다변량	2일	Normalizing Flow, 야코비안 행렬식

> **이것까지 있으면**: DDPM 논문을 수식 수준으로 따라갈 수 있고, Flow Matching의 기본을 이해할 수 있다.

9.3 Tier 3: Flow Matching / SDE 통합으로 갈 때

주제	수준	학습 시간	핵심 내용
SDE 기초	브라운 운동, Euler-Maruyama	3~5일	OU Process, 시뮬레이션
연속 방정식	직관 + 수식	2일	확률 보존, 속도장과 밀도의 관계
Fokker-Planck 방정식	직관 + 주요 결과	3~5일	SDE → PDE, 연속 방정식의 확산 확장
발산 (Divergence)	벡터 해석 기초	1~2일	$\nabla \cdot v$, 물리적 직관
Optimal Transport 기초	Wasserstein 거리 직관	2~3일	흙더미 비유, KL과의 비교

> **이것까지 있으면**: MIT 6.S184 강의 노트를 독립적으로 읽을 수 있고, 최신 논문의 수식을 따라갈 수 있다.

9.4 Tier 4: 연구 수준 (선택)

주제	필요 시점
Itô Calculus (Itô's Lemma)	Fokker-Planck 유도를 직접 하고 싶을 때
Girsanov 정리	SDE의 변분 추론 (CT-ELBO 등) 이해
측도론	SDE의 해의 존재/유일성을 엄밀하게 이해
Feynman-Kac 공식	SDE → PDE 연결의 일반 이론
Riemannian 기하	매니폴드 위의 Diffusion (분자 구조 생성 등)

> 대부분의 실무자/개발자에게는 Tier 4는 불필요하다. 연구자라도 관련 분야를 직접 다룰 때만 필요.

---

10. 추천 학습 자료

10.1 수학 기초

자료	내용	난이도
3Blue1Brown (YouTube)	선형대수, 미적분의 시각적 직관	★
Mathematics for Machine Learning (Deisenroth 교재, 무료 PDF)	선형대수 → 확률 → 최적화 통합	★★

Bishop, Pattern Recognition and Machine Learning Ch.1-2	확률론, 가우시안, 베이즈	★★★

10.2 확률론 & 정보이론

자료	내용	난이도
StatQuest (YouTube)	KL Divergence, 베이즈를 직관적으로	★
Cover & Thomas, Elements of Information Theory Ch.2	KL, Entropy, Mutual Info의 정석	★★★
Lilian Weng, "From Autoencoder to Beta-VAE" (블로그)	ELBO 유도를 가장 깔끔하게 설명	★★

10.3 미분방정식 & SDE

자료	내용	난이도
MIT 6.S184 Lecture Notes (diffusion.csail.mit.edu)	ODE → SDE → Fokker-Planck을 생성 모델 맥락에서 자체 완결적으로 설명	★★★
Peter Holderrieth 블로그 (peterholderrieth.com)	Fokker-Planck 직관적 유도	★★
Yang Song 블로그 (yang-song.net)	Score-Based → SDE 통합의 원저자 설명	★★★

10.4 Optimal Transport

자료	내용	난이도
Alex Williams, "A Short Intro to Optimal Transport" (블로그)	흙더미 비유부터 Wasserstein 까지, 시각적 설명	★
Larry Wasserman, "Optimal Transport" 강의 노트 (CMU)	통계학 관점의 간결한 정리	★★
Peyré & Cuturi, "Computational Optimal Transport"	OT의 정석 교재 (무료)	★★★★

부록: 각 생성 모델별 필요 수학 체크리스트

VAE

- [x] 가우시안 분포 (밀도, KL)
- [x] 베이즈 정리
- [x] ELBO 유도 (Jensen 부등식)

- [x] Reparameterization Trick
- [ ] ODE/SDE 불필요

GAN

- [x] 기본 확률 (기댓값, 분포)
- [x] Minimax 최적화
- [x] 기울기 (역전파)
- [ ] KL/ELBO 직접 사용 안 함 (하지만 이론 분석에는 등장)
- [ ] ODE/SDE 불필요

DDPM

- [x] 다변량 가우시안 (곱, 조건부, 아핀 변환)
- [x] KL Divergence (가우시안 KL)
- [x] ELBO → Simple Loss 유도
- [x] 마르코프 체인
- [x] Reparameterization Trick
- [△] ODE 기초 (DDIM 이해 시)
- [△] Score Function (Score-Based와의 관계)

Normalizing Flow

- [x] Change of Variables (다변량)
- [x] 야코비안 & 행렬식
- [x] 가역 함수

Score-Based Model

- [x] Score Function ($\nabla_x \log p$)
- [x] Fisher Divergence
- [x] Langevin Dynamics
- [x] 다중 스케일 노이즈

Flow Matching

- [x] ODE (벡터장, Euler 방법)
- [x] 연속 방정식
- [x] 선형 보간 (Interpolation)
- [△] Optimal Transport 직관
- [△] Fokker-Planck (SDE 확장 시)

SDE 통합 (Yang Song)

- [x] SDE (브라운 운동, 드리프트, 확산)
- [x] Euler-Maruyama
- [x] Fokker-Planck 방정식

- ☑ Probability Flow ODE
- ☑ Score Function
- [△] Itô Calculus (엄밀한 유도 시)

이 문서는 MIT 6.S184 (선수과목: 선형대수, 다변량 미적분, 기초 확률론), Stanford CS236, CMU 10-423의 수학적 요구사항을 분석하여 작성되었다.