# GloVe 이론적 배경

## 개요

GloVe(Global Vectors for Word Representation)는 2014년 스탠포드 대학의 Jeffrey Pennington, Richard Socher, Christopher Manning이 개발한 단어 임베딩 알고리즘입니다.

GloVe는 전역 단어-단어 동시출현 통계를 활용하여 단어의 벡터 표현을 학습합니다. 이는 기존의 지역적 문맥 창 기반 방법들과 차별화되는 접근법입니다.

**용어 정의**: 이 문서에서 "동시출현"과 "co-occurrence"는 같은 의미로 사용되며, "임베딩"과 "벡터 표현"도 동일한 개념을 나타냅니다. 수학 기호는 일관되게 사용됩니다 (예: X_ij는 동시출현 행렬, w_i는 단어 벡터).

## 단어 벡터 표현의 역사적 맥락

### 전통적 접근법의 한계

초기 자연어 처리에서는 단어를 원-핫 인코딩(one-hot encoding)으로 표현했습니다. 이 방법은 단어 간의 의미적 관계를 전혀 포착하지 못한다는 근본적인 한계가 있었습니다.

### 분산 표현의 등장

1980년대부터 연구자들은 단어의 **분산 표현(distributed representation)**에 주목하기 시작했습니다. 이는 단어를 고차원 공간의 실수 벡터로 표현하여 의미적으로 유사한 단어들이 벡터 공간에서 가까이 위치하도록 하는 아이디어입니다.

### Word2Vec의 혁신과 한계

2013년 Mikolov 등이 제안한 Word2Vec은 단어 임베딩 분야에 혁신을 가져왔습니다. Word2Vec은 두 가지 모델을 제시했습니다:

- **CBOW(Continuous Bag of Words)**: 주변 단어들로부터 중심 단어를 예측
- **Skip-gram**: 중심 단어로부터 주변 단어들을 예측

Word2Vec의 성공에도 불구하고 중요한 한계가 있었습니다:

1. **지역적 정보만 활용**: 작은 문맥 창 내의 정보만 사용
2. **전역 통계 무시**: 코퍼스 전체의 동시출현 통계를 직접적으로 활용하지 못함
3. **비효율적 학습**: 각 문맥 창을 독립적으로 처리하여 중복 계산 발생

# GloVe의 핵심 아이디어

## 전역 통계의 중요성

GloVe의 핵심 통찰은 **단어의 의미는 전역적 동시출현 통계에 인코딩되어 있다**는 것입니다. 예를 들어, "ice"와 "steam"이라는 단어를 구분하려면:

- "ice"는 “solid”, "cold"와 자주 함께 나타남
- "steam"은 “gas”, "hot"과 자주 함께 나타남

이러한 패턴은 전체 코퍼스의 통계를 통해서만 명확히 드러납니다.

## 동시출현 행렬 (Co-occurrence Matrix)

GloVe는 **동시출현 행렬 X**를 구축합니다. 여기서 X_ij는 단어 j가 단어 i의 문맥에서 나타나는 횟수입니다.

```
X_ij = 단어 j가 단어 i의 문맥에서 등장하는 횟수
```

문맥은 일반적으로 대상 단어 주변의 고정된 크기 창으로 정의됩니다.

# 확률 비율 (Probability Ratios)의 개념

### 조건부 확률 정의

동시출현 행렬로부터 조건부 확률을 정의할 수 있습니다:

```
P_ij = P(j|i) = X_ij / X_i
```

여기서 X_i = Σ_k X_ik는 단어 i의 총 문맥 등장 횟수입니다.

### 확률 비율의 직관

GloVe의 핵심 아이디어는 **확률 비율**에 있습니다. 세 단어 i, j, k를 고려할 때:

```
F(w_i, w_j, w_k) = P_ik / P_jk
```

이 비율이 단어 간의 관계를 명확히 드러냅니다:

- P_ik >> P_jk인 경우: 단어 k는 i와 더 관련이 깊음
- P_ik << P_jk인 경우: 단어 k는 j와 더 관련이 깊음
- P_ik ≈ P_jk인 경우: 단어 k는 i, j와 비슷한 관련성을 가짐

### 구체적 예시

"ice"와 "steam"을 구분하는 예시:

| k (probe word) | P(k\|ice) | P(k\|steam) | P(k\|ice)/P(k\|steam) |
|---|---|---|---|
| solid | $1.9\times10^{-4}$ | $2.2\times10^{-5}$ | 8.9 |
| gas | $6.6\times10^{-5}$ | $1.8\times10^{-4}$ | 0.36 |
| water | $2.2\times10^{-3}$ | $2.2\times10^{-3}$ | 1.0 |
| fashion | $3.2\times10^{-5}$ | $3.2\times10^{-5}$ | 1.0 |

이 표에서 확률 비율이 단어 간의 의미적 관계를 명확히 구분함을 볼 수 있습니다. 이러한 확률 비율의 개념은 GloVe 알고리즘에서 실제 학습 과정으로 구현됩니다.

## 목적 함수 유도 과정

### 기본 아이디어

GloVe의 목표는 단어 벡터들이 확률 비율 정보를 인코딩하도록 하는 것입니다. 즉, 벡터 공간에서의 관계가 확률 비율을 반영해야 합니다:

```
w_i^T w_k = log(P_ik / P_jk) = log(P_ik) - log(P_jk)
```

### 함수 형태의 가정

확률 비율을 벡터의 함수로 표현하기 위해 다음과 같은 일반적 형태를 가정합니다:

```
F(w_i, w_j, w_k) = P_ik / P_jk
```

이 함수는 벡터 공간에서 선형 구조를 가져야 하므로, 다음과 같이 단순화할 수 있습니다:

```
F((w_i - w_j)^T w_k) = P_ik / P_jk
```

### 로그 변환

확률의 곱셈을 덧셈으로 변환하기 위해 로그를 취합니다:

```
(w_i - w_j)^T w_k = log(P_ik / P_jk) = log(P_ik) - log(P_jk)
```

### 대칭성 고려

단어와 문맥의 역할이 본질적으로 대칭적이므로, 다음 조건을 만족해야 합니다:

```
w_i^T w_k = log(P_ik) = log(X_ik) - log(X_i)
```

이를 위해 편향 항을 도입합니다:

```
w_i^T w_k + b_i + b_k = log(X_ik)
```

여기서:

- b_i = log(X_i): 단어 i의 편향
- b_k: 문맥 단어 k의 편향

### 최종 목적 함수

위 관계식으로부터 최소제곱 목적 함수를 유도할 수 있습니다:

```
J = Σ_{i,j=1}^V (w_i^T w_j + b_i + b_j - log X_ij)²
```

여기서 V는 어휘 크기입니다.

## 가중치 함수 설계 원리

### 가중치 함수의 필요성

모든 동시출현 쌍이 동일한 중요도를 갖지는 않습니다. 다음과 같은 문제들이 있습니다:

1. **희소성 문제**: 많은 X_ij = 0 (로그 정의되지 않음)
2. **빈도 편향**: 매우 빈번한 단어 쌍이 결과를 지배
3. **노이즈**: 매우 드문 동시출현은 노이즈일 가능성

## 가중치 함수 f(X_ij)의 설계 원칙

이상적인 가중치 함수는 다음 조건들을 만족해야 합니다:

1. **연속성**: f(0) = 0 (희소 항목에 대해 0 가중치)
2. **단조성**: 빈도가 증가하면 가중치도 증가
3. **포화성**: 매우 높은 빈도에서는 가중치 증가율이 감소

## 구체적 가중치 함수

GloVe에서 사용하는 가중치 함수는 다음과 같습니다:

```
f(x) = {
(x/x_max)^α if x < x_max
1 if x ≥ x_max
}
```

일반적인 매개변수 값:

- x_max = 100: 포화점
- α = 0.75: 지수 매개변수

## 최종 가중치 적용 목적 함수

가중치 함수를 적용한 최종 목적 함수는:

```
J = Σ_{i,j=1}^V f(X_ij)(w_i^T w_j + b_i + b_j - log X_ij)²
```

이 함수는 다음과 같은 특성을 갖습니다:

- **희소성 처리**: X_ij = 0인 경우 자동으로 0 가중치

- **빈도 균형**: 매우 빈번한 쌍의 영향력 제한
- **효율성**: 0이 아닌 항목에 대해서만 계산

이러한 가중치 함수의 설계는 성능 최적화에서 중요한 역할을 합니다.

## 수학적 특성과 의미

### 벡터 공간의 구조

GloVe 임베딩은 다음과 같은 벡터 공간 구조를 갖습니다:

1. **선형 관계**: 단어 간의 관계가 벡터 차이로 표현됨
2. **대칭성**: 단어와 문맥 벡터의 대칭적 역할
3. **확률적 해석**: 벡터 내적이 로그 확률과 연결됨

### 기존 방법과의 차이점

| 특성 | Word2Vec | GloVe |
|---|---|---|
| 정보 활용 | 지역적 문맥 | 전역적 통계 |
| 학습 방식 | 온라인 학습 | 배치 학습 |
| 목적 함수 | 확률적 | 결정적 |
| 계산 복잡도 | O(corpus_size) | O(vocabulary$^2$) |

### 이론적 장점

1. **통계적 효율성**: 전역 통계를 직접 활용
2. **해석 가능성**: 명확한 수학적 동기
3. **확장성**: 다양한 가중치 함수 적용 가능

4. **안정성**: 결정적 목적 함수로 재현 가능한 결과

## 결론

GloVe는 단어 임베딩 학습에 대한 새로운 관점을 제시했습니다. 지역적 문맥 정보에 의존하던 기존 방법과 달리, 전역적 동시출현 통계를 직접 활용함으로써 더 풍부한 의미 정보를 포착할 수 있게 되었습니다.

핵심 기여는 다음과 같습니다:

1. **확률 비율의 활용**: 단어 간 관계를 확률 비율로 정량화
2. **전역 통계 통합**: 코퍼스 전체의 정보를 효율적으로 활용
3. **수학적 엄밀성**: 명확한 이론적 근거를 가진 목적 함수
4. **실용적 효율성**: 가중치 함수를 통한 계산 최적화

이러한 이론적 기반 위에서 GloVe는 다양한 자연어 처리 태스크에서 우수한 성능을 보여주었으며, 현재까지도 널리 사용되는 단어 임베딩 방법 중 하나입니다.

## 다음 단계

GloVe의 이론적 배경을 이해했다면, 다음 문서들을 통해 더 깊이 있는 학습을 계속할 수 있습니다:

- **GloVe 알고리즘 상세 분석**: 이론을 실제 알고리즘으로 구현하는 과정
- **Mittens 확장 개념**: GloVe를 확장한 도메인 적응 방법
- **구현체 코드 분석**: mittens 라이브러리의 실제 구현
- **성능 최적화 분석**: 벡터화와 GPU 가속 기법

**권장 학습 순서**: **이론(01)** → 알고리즘(02) → 확장(03) → 구현(04) → 성능(05)